

华东师范大学

《自然语言处理》

期末报告

CourseInsight: 中英双语课程评价智能分 析系统

小组成员:

姓名: 王佳妮 学号: 10232140440 学院: 计算机科学与技术

姓名: 柯文丽 学号: 10232140444 学院: 计算机科学与技术

2026 年 6 月 25 日

目录

- 1 项目背景 3
 - 1.1 问题描述与实际需求 3
 - 1.2 使用场景与目标用户 3
 - 1.3 项目目标与边界 3
- 2 主要功能 4
 - 2.1 系统核心功能 4
 - 2.1.1 单条评价分析 4
 - 2.1.2 批量 CSV 分析 4
 - 2.1.3 固定案例验证 4
 - 2.1.4 模型与系统信息 5
 - 2.2 功能模块划分 5
 - 2.3 功能设计原则 5
- 3 技术方案 6
 - 3.1 技术选型与理由 6
 - 3.2 系统总体架构 6
 - 3.3 数据流设计 7
 - 3.4 数据集与标签设计 7
 - 3.5 自动降级与运行稳定性 8
- 4 关键算法与模型原理 8
 - 4.1 双语预处理与情感文本标准化 8
 - 4.2 multilingual BERT 情感分类 9
 - 4.3 长文本滑动窗口推理 10
 - 4.4 规则校正与分层回退 10
 - 4.5 传统情感模型 10
 - 4.6 课程维度与证据识别 11
 - 4.7 关键词提取与相似评价检索 11
 - 4.8 结构化建议生成 11
 - 4.9 实验结果可视化 12
- 5 创新点 14
 - 5.1 创新性设计一：分层混合情感分析 14
 - 5.2 创新性设计二：仅对情感通道进行保守纠错 15
 - 5.3 创新性设计三：长文本加权聚合与可见元数据 15
 - 5.4 创新性设计四：证据约束的建议生成 15
 - 5.5 独立压力测试与技术贡献 15
- 6 界面展示 16

6.1	界面设计理念	16
6.2	评价分析页面	16
6.3	批量分析页面	17
6.4	测试验证与系统信息页面	18
7	系统部署与测试	19
7.1	环境要求	19
7.2	安装与启动步骤	19
7.3	源代码组成与提交范围	20
7.4	模型训练与实验复现	20
7.5	测试策略	21
7.6	代表性测试用例与结果	21
7.7	结果分析	22
8	思考与总结	23
8.1	开发过程中遇到的问题与解决方案	23
8.1.1	多源数据的标签一致性	23
8.1.2	中性与混合评价边界模糊	23
8.1.3	非规范英文表达影响模型输入	23
8.1.4	长文本截断导致信息丢失	23
8.1.5	模型与外部服务可能不可用	23
8.1.6	固定案例容易产生过度拟合式结论	23
8.2	项目局限性分析	24
8.3	未来改进方向	24
8.4	个人收获与反思	24
8.5	总结	25
9	小组分工与贡献	26
	参考文献	26

1 项目背景

1.1 问题描述与实际需求

课程评价是高校了解教学效果的重要信息来源。学生通常会在评价中同时谈到教师讲解、课程内容、作业量、考试范围、实验环境和学习收获。例如“老师讲得很清楚，但是作业太多”既包含正面态度，也包含明确的问题。如果只统计评分或采用简单正负词匹配，容易丢失评价中的转折关系和具体原因。

现有课程评价处理主要存在以下困难：

- **文本数量大。**期末集中收集评价时，教师和课程负责人难以逐条阅读并归纳。
- **表达形式复杂。**评价可能是中文、英文或中英混合文本，还可能包含缩写、拼写错误、否定、建议和讽刺等非规范表达。
- **情感与问题维度并不等价。**同一句话可以整体中性，但在作业任务或考试安排上包含明显负面反馈，仅输出情感标签不足以支持教学改进。
- **结果需要可解释。**教学场景不能只给出“负面”结论，还应说明命中了哪个课程维度、对应原文证据是什么，以及应该优先采取什么措施。
- **演示和部署环境不稳定。**深度模型、GPU 或外部大模型接口可能暂时不可用，系统仍需要完成基本分析，避免整个演示流程中断。

因此，本项目希望将非结构化课程评价转换为结构化信息，包括语言、情感标签、置信度、课程维度、关键词、证据片段、相似评价和改进建议，从而降低人工整理成本，并为教学改进提供更直接的依据。

1.2 使用场景与目标用户

系统面向三类主要用户：

1. **任课教师：**分析单条典型评价，了解学生认可点和具体困难，辅助调整教学节奏、作业量和实验安排。
2. **课程负责人：**批量导入课程评价 CSV，查看情感分布、课程维度分布和高频关键词，识别需要优先处理的共性问题。
3. **教学管理人员：**通过统一的结构化指标比较不同课程或不同学期的反馈趋势，并保留可追溯的原文证据。

典型使用流程为：教师上传评价数据，系统自动进行双语预处理和情感分类，再按照教学内容、授课方式、作业任务、考试安排、实验实践、学习收获六个维度归纳问题，最后生成便于教师阅读的总结与建议。

1.3 项目目标与边界

本项目的核心目标不是替代教师做教学决策，而是构建一个可运行、可解释、可降级的 NLP 辅助系统。具体目标如下：

- 支持中文、英文和中英混合课程评价；
- 完成正面、中性、负面三分类，并处理常见混合评价；
- 将评价映射到课程维度，同时展示命中关键词和原文证据；
- 支持单条分析、批量分析、测试验证和模型指标展示；
- 在 BERT、传统模型或外部 API 不可用时保持主要流程可运行；
- 提供可复现的数据处理、模型训练、消融实验和压力测试脚本。

项目在设计阶段明确区分三类结论：独立测试集用于比较模型性能，固定业务案例用于验证课堂演示流程，独立压力测试用于观察复杂表达下的鲁棒性。三类结果分别呈现，避免将某一组案例上的满分直接解释为系统整体准确率。

项目成果概述：本项目最终实现了一个可运行的中英双语课程评价分析系统，支持单条评价分析、批量 CSV 分析、固定案例验证和系统信息展示。系统综合使用 multilingual BERT、TF-IDF Logistic Regression、规则校正和 LLM 建议生成，将课程评价转换为情感标签、课程维度、关键词、原文证据、相似评价和教学建议。multilingual BERT 在 2280 条独立测试样本上的 Accuracy 为 0.7461，Macro-F1 为 0.7457；完整混合流程在 12 条固定业务案例上通过 12/12，在 48 条独立压力测试上通过 34/48。系统同时设计了模型回退和本地模板兜底机制，以保证课堂演示和部署环境不稳定时仍能运行。

2 主要功能

2.1 系统核心功能

2.1.1 单条评价分析

用户可以输入中文、英文或中英混合评价，也可以选择系统内置示例。系统返回语言识别结果、情感标签、置信度、模型来源、课程维度、命中证据、关键词和相似评价。当启用建议生成时，系统将结构化分析结果发送给 ChatECNU；接口不可用时自动使用本地模板生成同样结构的总结与建议。

2.1.2 批量 CSV 分析

系统支持上传包含 text、review 等常见文本字段的 CSV 文件。批量分析使用向量化或批处理推理，输出有效评价数量、正负面占比、主要课程维度、高频关键词和逐条分析明细，并支持下载结果 CSV。该功能适合期末集中评价或问卷开放题的快速整理。

2.1.3 固定案例验证

测试验证页面读取 data/test_cases.csv 中的 12 条固定案例，一键执行完整 NLP 流程，并同时比较情感标签和课程维度是否符合预期。页面给出通过数量、失败数量、总通过率和逐条结果，可作为课堂演示中的稳定案例。

2.1.4 模型与系统信息

系统信息页面展示传统分类器对比、BERT 指标、混淆矩阵、分语言结果和消融实验。页面同时报告当前实际启用的情感后端与 LLM 状态，便于演示时解释系统是在使用 BERT、TF-IDF 还是规则兜底。

2.2 功能模块划分

表 1 系统功能模块划分

模块	主要文件	功能说明
前端交互	app.py	提供单条分析、批量分析、测试验证和系统信息四个页面
文本预处理	preprocess.py、 sentiment_ normalizer.py	语言识别、文本清洗、双语分词、缩写展开和受限拼写纠错
情感分析	bert_sentiment.py、 nlp_analyzer.py	BERT 推理、规则校正、TF-IDF 回退和统一结果编排
课程维度	topic_analyzer.py	识别六类课程维度，并返回命中关键词和原文证据
关键词与检索	keyword_ extractor.py、 similarity.py	提取高频关键词并按余弦相似度检索相关评价
建议生成	llm_client.py	调用 ChatECNU 生成结构化建议，异常时使用本地模板
训练与评估	train_model.py、 train_bert.py、 scripts/	模型训练、指标保存、消融实验和独立压力测试

各功能模块在系统中的层次关系见图 1，从评价输入到结构化结果和教学建议的处理顺序见图 2。模块表、总体架构图和数据流图共同说明了页面功能、后端服务与模型资源之间的对应关系。

2.3 功能设计原则

系统功能设计遵循“先结构化分析，再生成自然语言建议”的原则。情感标签由可评估的分类模型与规则模块决定，大语言模型只接收情感、课程维度、关键词和证据等结构化结果，不直接替代分类器。这样可以减少生成模型对核心标签的不可控影响，也能够没有 API 时保持分析结果一致。

另一个原则是“输出结论必须尽量附带证据”。课程维度不是只返回一个名称，而是同时记录命中关键词、关键词位置和附近的原文片段。教师可以从“系统判断”快速回到“学生原话”，降低错误归纳带来的风险。

3 技术方案

3.1 技术选型与理由

表 2 主要技术选型

层次	技术或工具	选型理由
开发语言	Python 3.10+	NLP 与机器学习生态完整，便于整合数据处理、模型训练和前端应用
Web 前端	Streamlit	能快速构建数据应用，原生支持表格、图表、文件上传、缓存和下载
数据处理	Pandas、NumPy	适合 CSV 清洗、批量统计、训练数据划分和结果导出
中文处理	jieba	部署轻量，适合课程领域词汇的基础分词和关键词统计
传统模型	scikit-learn	提供 TF-IDF、Logistic Regression、Naive Bayes、Linear SVM 和评估指标
深度模型	PyTorch、Transformers	支持 multilingual BERT 微调、GPU/CPU 切换、批量推理和模型保存
建议生成	ChatECNU API	与聊天补全接口兼容，可将结构化分析结果转换为自然语言教学建议
测试工具	unittest	Python 标准库自带，覆盖预处理、模型编排、降级路径和脚本输出

3.2 系统总体架构

系统采用分层结构，将页面交互、NLP 编排、模型推理、规则知识和外部服务分开。前端只调用统一分析接口，不直接依赖某一种模型；因此更换情感后端或关闭 LLM 不需要修改页面逻辑。




图 1 CourseInsight 系统总体架构

3.3 数据流设计




图 2 CourseInsight 双文本通道与核心数据流

系统对同一条评价保留两种文本表示：原始文本用于页面展示、课程维度、关键词和证据提取；标准化文本只用于情感分类。这样既能提高噪声文本的分类稳定性，又不会因为自动纠错而改变学生原话。

3.4 数据集与标签设计

训练数据共 9120 条，覆盖中英文课程评价。三个情感类别各 3040 条，保持完全均衡。数据以 Coursera 课程评论为主体，并补充高校课程场景的人工构造与标注样本，用于验证双语处理流程。

表 3 训练数据构成

数据来源	数量	语言	主要用途
Coursera 课程评论	9000	英文	模型训练和主要量化评估
人工课程评价	120	中文	双语流程验证和课堂演示
合计	9120	中英双语	正面、中性、负面各 3040 条

Coursera 课程评论主要用于英文情感模型训练和量化评估；人工课程评价样本根据高校课程评价场景构造，用于覆盖中文、中英混合、作业、考试和实验等课堂演示场景。人工样本不包含真实学生姓名、学号或其他隐私信息，仅用于双语功能验证和测试用例构建。两类数据承担的任务不同，报告中的模型性能结论主要依据固定划分的独立测试集，不以少量人工样本单独推断真实校园场景的整体效果。

标签定义为：正面表示主要认可或满意；负面表示主要抱怨或明确问题；中性不仅包含态度不明显的评价，也包含建议型评价和正负信息相对平衡的混合评价。该定义更符合教学反馈场景，因为“内容很好，但考试范围不清楚”不应被简单压缩为单一的正面或负面结论。

3.5 自动降级与运行稳定性

情感后端默认设置为 `auto`。系统优先加载本地 BERT 权重；若权重缺失、依赖不可用或推理失败，则回退到 TF-IDF Logistic Regression；如果传统模型文件也不可用，则使用规则模型。建议生成同样具有降级路径：ChatECNU 调用失败时，本地模板根据情感和课程维度生成总结、问题与建议。该设计保证了课堂演示中即使网络或 GPU 出现异常，系统仍能提供完整的基本结果。

4 关键算法与模型原理

4.1 双语预处理与情感文本标准化

基础预处理首先删除 URL、异常符号和多余空白，再识别文本语言。中文使用 `jieba` 分词，英文使用正则表达式分词并过滤常见停用词。为了保留课程领域信息，系统不会删除“作业、考试、实验、讲解、收获”等对教学分析有意义的词。真实评论中经常出现 `tbh`、`idk`、`cant`、`crs` 等缩写，以及 `excelnt`、`confuzing`、`uncler` 等拼写错误。系统在情感分类前增加独立标准化层，将常见缩写展开，并只对情感词执行受限纠错。自动纠错必须满足候选唯一、相同词首，且最多只有一次漏字、多字或相邻字母换位；合法词形和技术名词受到保护。部分转换示例如表 4。

表 4 噪声情感文本标准化示例

原始表达	送入情感分类器的标准化表达
Tbh this crs is dificult	To be honest, this course is difficult
I cant recomed this crs borng and uncler gooooood	I cannot recommend this course boring and unclear good

标准化后的文本只用于情感分类，原始文本继续用于页面展示、关键词、课程维度和证据提取。这一“双文本通道”避免了自动纠错修改学生原话，也保证最终证据能够与用户输入直接对应。

4.2 multilingual BERT 情感分类

BERT 使用 Transformer 编码器，通过双向自注意力建模词语在上下文中的关系。对于输入 Token 序列 $x_1, x_2, \dots, x_n$ ，模型得到各位置的上下文表示，并使用 [CLS] 位置的最终表示 h_{CLS} 完成三分类：

$$\mathbf{p} = \text{softmax}(W h_{\text{CLS}} + \mathbf{b}), \quad (1)$$

其中 $\mathbf{p}$ 分别表示 negative、neutral 和 positive 的概率，最终标签为概率最大的类别。项目采用 bert-base-multilingual-cased，利用其多语言词表同时处理中文和英文。

表 5 BERT 训练配置

参数	数值	参数	数值
训练/验证/测试集	5472/1368/2280	随机种子	42
训练轮数	2	批大小	8
最大序列长度	160	学习率	2×10^{-5}
权重衰减	0.01	最优模型指标	Macro-F1

验证集用于每轮训练后的模型选择，独立测试集只在训练完成后评估一次。训练时若 CUDA 可用则启用 FP16 和 GPU，否则可在 CPU 上运行。部署阶段采用懒加载方式，第一次分析时加载模型，后续请求复用同一实例。

4.3 长文本滑动窗口推理

直接截断长评价会丢失后半部分信息。系统将超过最大长度的 Token 序列按滑动窗口切分，默认最大长度为 160，重叠 32 个 Token，单条评价最多保留 16 个窗口。整条评价的加权分类概率为：

$$p = \frac{\sum_{i=1}^m w_i p_i}{\sum_{i=1}^m w_i}.$$

其中， p_i 表示第 i 个窗口的分类概率， w_i 表示该窗口的有效 Token 数， m 表示窗口数量。使用有效 Token 数加权可以避免短尾窗口和完整窗口具有相同影响。系统还在结果中记录窗口数量、Token 数量和是否达到窗口上限，便于页面提示用户存在未处理的超长内容。

4.4 规则校正与分层回退

BERT 能理解大部分上下文，但对课程评价中的混合态度、局部否定和固定业务定义仍可能产生偏差。规则模块统计中英文正负信号，并检测“但是、但、不过、but、however”等转折结构。其主要处理逻辑包括：

- 正负信号同时出现且相对平衡时，将结果校正为中性；
- “不差、并非没有帮助”等否定负面表达作为弱正面信号；
- “不清楚、not useful”等否定正面表达作为负面信号；
- 建议型表达默认保持中性，避免把“希望增加代码示例”误判为强负面；
- 对部分明显讽刺或隐含抱怨使用有限语义规则，但不声称能够完整解决讽刺识别。

系统默认采用 auto 后端，执行顺序为：

$$\text{BERT} + \text{规则校正} \rightarrow \text{TF-IDF Logistic Regression} \rightarrow \text{纯规则模型}. \quad (2)$$

该顺序将语义效果较好的 BERT 放在首位，同时保留体积小、启动快的传统模型和无需模型文件的规则兜底。

4.5 传统情感模型

传统模型将预处理后的文本转换为 TF-IDF 向量。词 t 在文档 d 中的权重表示为：

$$\text{tfidf}(t, d) = \text{tf}(t, d) \log \frac{N}{\text{df}(t) + 1}, \quad (3)$$

其中 N 为文档总数， $\text{df}(t)$ 为包含词 t 的文档数。项目使用一元与二元词组、最多 30000 个特征，并比较 Dummy、Logistic Regression、Naive Bayes 和 Linear SVM。最佳传统模型为 Logistic Regression。

表 6 传统模型与 BERT 测试结果

模型	Accuracy	Macro-F1
Dummy Most Frequent	0.3333	0.1667
Naive Bayes	0.6772	0.6785
Linear SVM	0.6811	0.6795
Logistic Regression	0.6904	0.6906
multilingual BERT	0.7461	0.7457

BERT 相比 Logistic Regression 的 Accuracy 提高约 5.57 个百分点，Macro-F1 提高约 5.51 个百分点。BERT 对 `positive` 类效果最好，而 `neutral` 类由于混合评价和建议型表达较多，仍是最难识别的类别。

4.6 课程维度与证据识别

系统使用面向课程场景的双语领域词典识别六个维度：教学内容、授课方式、作业任务、考试安排、实验实践和学习收获。例如出现“`assignments`”和“`deadline`”时，系统识别为“作业任务”；出现“`setup`”和“`code`”时识别为“实验实践”。对于每个命中维度，系统不仅返回维度名称，还记录最先出现的关键词、出现位置和关键词附近的原文片段。维度结果按首次出现位置排序，因此能够保留评价的叙述顺序。这种方法虽然没有采用复杂主题模型，但在固定课程场景中具有实现简单、结果稳定、容易解释和便于扩展的优点。

4.7 关键词提取与相似评价检索

关键词模块统计预处理后词项频次并过滤停用词，用于批量分析中的高频反馈概览。相似评价检索将文本表示为词频向量，并计算余弦相似度：

$$\text{sim}(A, B) = \frac{\mathbf{v}_A \cdot \mathbf{v}_B}{\|\mathbf{v}_A\|_2 \|\mathbf{v}_B\|_2}. \quad (4)$$

该方法计算开销低，适合当前规模的课堂演示数据。后续可以替换为句向量模型，提高语义相似但表面词汇不同的评价之间的召回率。

4.8 结构化建议生成

大语言模型不直接接收一段孤立评论并自由判断，而是接收情感标签、课程维度、关键词、证据片段和相似评价，并被要求输出 `summary`、`problems`、`suggestions` 和 `risk level` 等固定字段。温度设置为 0.2，以降低输出随机性。调用失败时，本地模板根据同一结构化输入生成结果，因此分类和证据不会受到外部服务状态影响。

4.9 实验结果可视化

为避免只依赖表格陈述实验结论，本节使用训练数据、模型评估文件和训练日志生成可复现图表。所有图片均由 `scripts/generate_report_charts.py` 自动生成，数据来源与前文表格一致。训练数据按照 60%、15% 和 25% 划分训练集、验证集和独立测试集，独立测试集规模为 2280 条。




图 3 独立测试集上不同情感分类模型性能对比

图 3 将传统基线和最终 BERT 模型置于同一坐标系中，评价指标为 Accuracy 和 Macro-F1。multilingual BERT 的 Accuracy 为 0.7461，Macro-F1 为 0.7457，分别比最佳传统模型 Logistic Regression 提高约 5.57 和 5.51 个百分点，说明上下文表示对课程评价中的转折、否定和混合态度具有实际价值。




图 4 multilingual BERT 独立测试集混淆矩阵

图 4 展示了 multilingual BERT 在 negative、neutral 和 positive 三类上的具体分类情况。正面类别识别效果最好；中性类别有 228 条被误判为负面、72 条被误判为

正面，是最主要的错误来源。这说明课程评价中的建议型表达、轻度抱怨和正负混合表达仍容易与单一极性混淆，不能只依赖总体指标判断模型效果。




图 5 multilingual BERT 微调过程

图 5a 显示训练损失在两个 Epoch 内总体下降，说明模型逐渐拟合课程评价情感分类任务。图 5b 显示验证集 Accuracy 从 0.7003 提升至 0.7230，Macro-F1 从 0.7039 提升至 0.7225。第二轮训练仍带来稳定增益，但验证损失未同步明显下降，因此当前训练轮数保持为 2，以控制过拟合风险和训练成本。






图 6 固定业务案例演示集消融结果

为验证各模块的实际作用，项目分别运行纯规则、TF-IDF、BERT 和完整混合流程。图 6 显示，TF-IDF 单模块通过 7/12，BERT 单模块通过 10/12，而完整流程通过 12/12。纯规则同样在这组固定案例上达到满分，是因为案例中包含较多规则能够直接覆盖的典型表达。**固定业务案例主要用于验证课堂演示流程，不作为泛化性能结论。**为避免规则模型满分造成误解，项目进一步使用未参与规则开发的 48 条独立压力测试检验复杂输入下的表现。



(a) 整体 Accuracy 与 Macro-F1



(b) 分类别通过数

图 7 独立压力测试中不同方法的整体性能与分类别通过率。压力测试共 48 条，覆盖缩写、拼写、否定、讽刺、隐含抱怨、中英混合、长文本和混合情感，每类 6 条

图 7 表明，混合流程在 48 条独立压力测试上的 Accuracy 和 Macro-F1 均明显高于三个单独模块。其优势主要集中在缩写、拼写错误、否定、中英混合和长文本场景：中英混合通过 6/6，缩写、拼写、否定和长文本均通过 5/6。相较 BERT 单模块，完整流程的 Accuracy 从 54.2% 提升至 70.8%，Macro-F1 从 54.2% 提升至 72.2%。另一方面，讽刺仅通过 1/6，隐含抱怨仅通过 3/6，仍是当前系统最主要的失败类型。

5 创新点

5.1 创新性设计一：分层混合情感分析

项目没有将“使用 BERT”本身作为创新点，而是针对课程评价的真实问题设计了分层混合流程。BERT 负责主要上下文语义判断；规则模块处理课程场景中可明确描述的转折、否定、建议和混合评价；传统模型和纯规则用于自动回退。不同方法承担各自适合的任务，而不是简单投票。

12 条固定业务案例的消融结果见图 6。这些案例主要用于验证课堂演示流程，不等同于独立泛化测试。纯规则取得满分，是因为案例集中包含较多规则能够直接覆盖的典型表达；因此项目另外使用未参与规则开发的 48 条压力测试评估复杂输入下的鲁棒性。

5.2 创新性设计二：仅对情感通道进行保守纠错

多数文本清洗流程会直接修改整个输入，从而使后续证据片段与学生原话不一致。本项目将“用于分类的标准化文本”和“用于展示与证据的原始文本”分开。缩写展开、重复字母收缩和拼写纠错只进入情感分类通道；课程维度、关键词和证据仍从原文产生。

同时，纠错策略限制在情感词范围内，并要求极小编辑距离与唯一候选，避免将课程名、编程库名称或合法英文词形错误修改。这种设计在提高噪声文本鲁棒性的同时，保留了分析结果的可追溯性。

5.3 创新性设计三：长文本加权聚合与可见元数据

系统没有直接截断超过 160 Token 的评价，而是使用带重叠的滑动窗口推理，并按每个窗口的有效 Token 数加权聚合概率。与简单平均相比，这可以降低短尾窗口对整体结果的过度影响。系统还把窗口数量、Token 数和截断标志传递到最终分析结果，使前端能够明确提示超长输入是否达到处理上限，而不是静默丢弃信息。

5.4 创新性设计四：证据约束的建议生成

系统把大语言模型限制在“表达与归纳”环节，而不是让其直接决定情感和课程问题。提示词要求建议中的问题维度优先来自自己识别的课程维度，证据必须引用原始评论、主题证据或相似评价。即使 LLM 不可用，本地模板也会输出相同字段。这种结构降低了生成式模型幻觉对核心分析结论的影响。

5.5 独立压力测试与技术贡献

独立压力测试包含 48 条样本，每类 6 条，覆盖缩写、拼写错误、否定、讽刺、隐含抱怨、中英混合、长文本和混合情感。该数据不参与模型训练，也不用于固定业务规则的反复调试。

完整混合流程通过 34/48 条样本，Accuracy 为 0.7083，Macro-F1 为 0.7217，均高于 rule-only、TF-IDF-only 和 BERT-only。总体指标与分类结果见图 7。

混合流程在缩写、拼写、否定和长文本上均达到 5/6，在中英混合上达到 6/6，说明文本标准化、规则校正和分段推理具有实际增益。另一方面，讽刺类别仅通过 1/6，隐含抱怨仅通过 3/6。这些结果说明项目的技术贡献主要是提高课程评价系统在常见噪声和混合表达下的工程鲁棒性，而不是彻底解决所有复杂语用现象。将失败类型如实保留，也为后续数据扩充和模型改进提供了明确方向。

6 界面展示

6.1 界面设计理念

CourseInsight 使用 Streamlit 构建宽屏数据应用，整体设计强调“先看结论，再看证据，最后执行操作”。侧边栏固定显示功能导航、当前情感模型后端和 LLM 服务状态，避免用户在不同页面间切换时失去运行环境信息。页面主体采用卡片、指标和分区布局，把长文本分析拆解为可快速浏览的结构。

界面设计遵循以下原则：

- **任务导向：**导航只保留评价分析、批量分析、测试验证和系统信息四个主要入口；
- **状态可见：**显示 BERT、TF-IDF 或规则模式，以及 LLM 是否使用本地兜底；
- **结论分层：**先展示情感、置信度和风险，再展示课程维度、证据、相似评价和建议；
- **降低输入成本：**内置中文、英文和中英混合示例，批量页面支持常见 CSV 字段；
- **支持演示：**测试页面可以一键运行固定案例，系统信息页面集中展示模型指标。

6.2 评价分析页面

评价分析页面左侧为文本输入区，右侧为示例选择和建议生成开关。完成分析后，页面展示语言、情感标签、置信度和模型来源，并继续给出课程维度、关键词、原文证据、相似评价和教学改进建议。

The screenshot shows the CourseInsight evaluation analysis interface. It is divided into three main sections: 1. Input (输入评价), 2. Analysis (运行分析), and 3. Results (查看结果). The input section contains a text area for evaluation content and a 'Start Analysis' button. The analysis section shows settings for example evaluation, analysis mode, and analysis type. The results section displays a summary card for 'Neutral / Mixed Feedback' with a 72% confidence score, and three detailed cards for language (Chinese), model (BERT + Rule-based), and course dimension (4).

图 8 单条评价分析页面的输入区域、情感结论、置信度和模型来源

6.3 批量分析页面

批量分析页面支持上传 CSV 或使用内置样本。分析后首先展示有效评价数量、正面占比、负面占比和首要课程维度，再展示情感分布、课程维度分布、高频关键词和逐条结果。分析明细可直接下载为 CSV，便于后续人工复核和归档。




图 9 批量评价分析页面的核心指标与分布统计

6.4 测试验证与系统信息页面

测试验证页面用于一键运行 12 条固定案例，并显示通过数量、失败数量和逐条对比。系统信息页面展示传统模型、BERT、分语言指标、混淆矩阵和消融实验，使演示中的模型结论能够与保存的实验文件一致。




图 10 固定案例测试验证页面的 12/12 通过结果与逐条对比

7 系统部署与测试

7.1 环境要求

表 7 推荐运行环境

项目	要求或说明
操作系统	Windows 10/11; Linux 与 macOS 也可运行
Python	3.10 或以上版本
基础依赖	Streamlit、Pandas、NumPy、jieba、scikit-learn、Matplotlib 等
BERT 依赖	PyTorch、Transformers、Accelerate
硬件	基础功能可使用 CPU; BERT 推荐使用支持 CUDA 的 NVIDIA GPU
模型文件	传统模型约 1.3 MB; BERT 权重约 711 MB, 需要单独携带或下载
可选服务	ChatECNU API; 未配置时自动使用本地建议模板

7.2 安装与启动步骤

1. 在项目根目录创建并激活虚拟环境:

```
python -m venv .venv
.venv\Scripts\activate
```

2. 安装基础依赖和 BERT 依赖:

```
pip install -r requirements.txt
pip install -r requirements-bert.txt
```

3. 如需使用大语言模型建议, 将 .env.example 复制为 .env, 填写 LLM_API_KEY、LLM_BASE_URL 和 LLM_MODEL。不配置 API 也不会影响情感分析、课程维度和本地建议生成。
4. 确认 BERT 模型目录为 outputs/bert_model, 或通过 BERT_MODEL_PATH 指定其他目录。若没有 BERT 权重, 系统自动使用传统模型。
5. 启动应用:

```
streamlit run app.py
```

6. 浏览器访问 Streamlit 输出的本地地址, 依次检查评价分析、批量分析、测试验证和系统信息页面。

7.3 源代码组成与提交范围

电子版代码以项目根目录为提交单位，包含完整的应用入口、NLP 实现、训练评估脚本、自动测试和环境配置说明。主要内容如下：

- `app.py`: Streamlit 应用入口及四个功能页面；
- `src/`: 预处理、BERT 与传统模型推理、课程维度、关键词、相似评价和建议生成模块；
- `scripts/`: 数据构建、消融实验、压力测试和报告图表生成脚本；
- `tests/` 与 `data/test_cases.csv`: 自动测试和固定演示案例；
- `requirements.txt`、`requirements-bert.txt` 和 `.env.example`: 依赖与配置模板；
- `models/`: 可直接运行的传统模型文件。BERT 权重体积较大，可随最终电子材料单独提交；缺少该权重时系统会自动回退到传统模型，基本功能仍可运行。

提交时不包含本地密钥文件 `.env`、Python 缓存和运行日志，避免泄露凭据或混入临时文件。

7.4 模型训练与实验复现

传统模型训练命令如下：

```
python -m src.train_model ^
--data data/processed/bilingual_reviews_train.csv ^
--model-dir models
```

BERT 训练命令如下：

```
python -m src.train_bert ^
--data data/processed/bilingual_reviews_train.csv ^
--model-name bert-base-multilingual-cased ^
--output-dir outputs/bert_model ^
--metrics-path outputs/bert_metrics.json
```

固定案例消融实验和独立压力测试分别使用：

```
python scripts/run_ablation_experiment.py ^
--cases data/test_cases.csv ^
--output-dir outputs/reports ^
--model-dir models
```

```
python scripts/run_stress_test.py ^
```

```
--cases data/stress_test_cases.csv ^
--output-dir outputs/reports/stress_test_final ^
--model-dir models
```

7.5 测试策略

项目测试分为三个层次：

- 1. **单元与集成测试：**覆盖文本清洗、语言识别、分词、情感标准化、长文本窗口、课程维度证据、相似度、模型优先级、降级路径、LLM 本地兜底、数据脚本和页面数据格式。
- 2. **固定业务案例：**12 条中英文课程评价，用于验证课堂演示中的情感和课程维度结果。
- 3. **独立压力测试：**48 条复杂表达，用于观察缩写、拼写、否定、讽刺、中英混合和长文本下的泛化表现。

单元测试运行命令为：

```
python -m unittest discover -s tests
```

7.6 代表性测试用例与结果

表 8 给出 8 个代表性案例，超过作业要求的至少 5 个测试用例。结果来自当前完整混合流程的固定案例实验。

表 8 代表性测试用例与结果

编号	输入评价	预期情感	预期课程维度	结果
1	老师讲课很清楚，内容也很有用	正面	授课方式、教学内容	通过
2	作业太多了，每周都做不完	负面	作业任务	通过
3	实验环境配置太复杂，经常报错	负面	实验实践	通过
4	课程内容不错，但是考试范围不太明确	中性	教学内容、考试安排	通过
5	这门课难度比较大，但学完之后收获很多	中性	教学内容、学习收获	通过
6	希望老师能多给一些代码示例	中性	实验实践、教学内容	通过

编号	输入评价	预期情感	预期课程维度	结果
7	The instructor explains concepts clearly and the examples are helpful	正面	授课方式、学习收获	通过
8	The assignments are too many and the deadlines are stressful	负面	作业任务	通过

7.7 结果分析

固定案例中，TF-IDF 单独通过 7/12，BERT 单独通过 10/12，完整流程通过 12/12。BERT 改善了英文上下文和中文短句的判断，规则校正进一步处理了“内容不错，但是考试范围不明确”等混合评价。

48 条独立压力测试中，完整流程通过 34 条，Accuracy 为 0.7083，Macro-F1 为 0.7217。中英混合类别通过 6/6，缩写、拼写、否定和长文本类别均通过 5/6，说明针对噪声文本和长文本的设计有效。讽刺类别仅通过 1/6，是当前最主要的失败来源；因此报告不以固定案例满分替代独立测试结论。

8 思考与总结

8.1 开发过程中遇到的问题与解决方案

8.1.1 多源数据的标签一致性

课程评价来自公开评论与人工构造场景，不同来源的表达风格和信息密度存在差异。项目首先统一正面、中性、负面的标注标准，再对三类标签进行均衡采样，并固定训练、验证、测试划分。这样能够让传统模型、BERT 和混合流程在相同数据基础上比较，也避免数据来源差异直接干扰实验结论。

8.1.2 中性与混合评价边界模糊

三分类任务中，中性类别不仅包括没有明显态度的文本，还包括建议型表达和正负混合评价。传统 TF-IDF 模型容易只关注强情感词，BERT 也可能将转折句推向某一极性。项目通过统一标签定义、转折规则和正负信号平衡判断，将“讲解清楚但作业太多”归入中性，并保留各课程维度的具体问题。

8.1.3 非规范英文表达影响模型输入

在线评论中存在缩写、漏字、重复字母和拼写错误。若全面启用通用拼写纠错，容易误改课程名和技术词；若完全不处理，又会损失情感信号。最终方案是在情感通道中使用受限词典和极小编辑操作，只纠正高置信度情感词，并保留原文用于证据展示。

8.1.4 长文本截断导致信息丢失

BERT 的输入长度有限，直接截断可能只保留评价开头。项目实现带重叠的滑动窗口，并按有效 Token 数加权聚合各窗口概率。同时限制最大窗口数并暴露截断元数据，在保证计算可控的情况下尽量保留完整信息。

8.1.5 模型与外部服务可能不可用

BERT 权重体积较大，加载需要时间；课堂网络也可能导致 ChatECNU API 失败。项目将模型加载设计为懒加载和实例复用，情感分析提供 BERT、TF-IDF、规则三级后端，建议生成提供 API 与本地模板两级方案。前端显示实际运行状态，避免用户误以为系统始终在使用同一种模型。

8.1.6 固定案例容易产生过度拟合式结论

固定业务案例适合演示，但规则可能因为覆盖这些表达而取得很高成绩。项目额外建立 48 条独立压力测试，并按表达类型和语言统计结果。压力测试暴露了讽刺和隐含抱怨的不足，使评估结论更加真实，也避免将 12/12 的演示结果错误解释为整体准确率 100%。

8.2 项目局限性分析

1. **真实场景覆盖仍可扩展。**当前数据主要覆盖课程评价常见表达，尚未覆盖更多学科、学期和院校环境，跨场景泛化能力仍需持续验证。
2. **课程维度依赖词典。**领域词典易解释、部署轻量，但难以识别没有显式关键词的隐含主题，也需要人工维护新课程术语。
3. **讽刺和隐含抱怨识别较弱。**压力测试中讽刺通过率仅 1/6，说明有限规则和当前训练数据不足以处理复杂语用现象。
4. **相似评价仍基于词频。**余弦相似度实现简单，但对同义改写和跨语言语义相似的召回能力有限。
5. **大模型建议仍需人工确认。**即使提示词要求引用证据，生成内容也不应直接作为教学决策，教师需要结合课程实际情况复核。
6. **模型部署成本较高。**BERT 权重约 711 MB，CPU 首次加载和推理速度不如传统模型，不适合资源极低的环境。
7. **尚未进行真实用户研究。**当前主要验证算法和系统流程，还缺少教师实际使用后的可用性评价与改进效果追踪。

8.3 未来改进方向

- 与真实课程合作，在脱敏和授权前提下收集跨课程、跨学期评价，并由多人复核标签；
- 对不同语言 and 不同课程场景进行分层评估，增加置信区间和跨学期测试；
- 使用句向量或多语言语义检索模型替换词频余弦相似度；
- 将课程维度识别升级为多标签分类，同时继续保留证据抽取和规则解释；
- 针对讽刺、隐含抱怨和复杂否定构建专门训练集，而不是无限增加手写规则；
- 引入模型蒸馏、量化或 ONNX Runtime，减小部署体积并提升 CPU 推理速度；
- 加入课程、学期和教师维度的历史趋势对比，以及人工反馈修正机制；
- 对 LLM 建议增加事实一致性检查、敏感信息脱敏和人工确认工作流。

8.4 个人收获与反思

本项目使我们完整经历了 NLP 应用从需求分析、数据构建、模型训练到前端部署和测试验证的过程。最大的收获是认识到，一个可演示、可解释、可复现的应用并不只由单个高分模型组成。数据标签定义、失败路径、异常处理、评估集设计和用户界面同样决定系统质量。

在算法方面，我们从 TF-IDF 词袋表示逐步过渡到 BERT 上下文语义表示。TF-IDF 实现简单、训练和推理速度快，但难以理解复杂的转折、否定和语义关系；BERT 能利用上下文改善判断，却带来了更高的模型体积和部署成本。两类模型的对比

使我们理解，算法选择不能只追求复杂度，而要同时考虑任务特点、可解释性、运行资源和失败后的回退路径。

在评估方面，项目让我们认识到 **Accuracy** 不能完整代表三分类系统的效果，还需要结合 **Macro-F1**、混淆矩阵、分类别指标和具体错误类型进行分析。固定案例上的 12/12 适合验证演示流程，但独立压力测试中的 34/48 更能暴露讽刺、隐含抱怨和复杂否定等泛化问题。区分“演示效果”和“泛化能力”，是本次 NLP 实验设计中最重要收获之一。

在应用开发方面，我们进一步认识到 NLP 系统并不是简单调用一个模型，而是由文本预处理、标签设计、模型训练、规则约束、证据提取、异常处理、测试用例、界面展示和部署说明共同构成。项目将 LLM 限制在结构化建议表达环节，而不让其直接决定可量化评估的情感标签，也让我们理解生成式模型在实际系统中需要受到结构化输入和原文证据约束。

如果重新开始，我们会更早确定标签规范、独立测试集和复杂表达分类，而不是在后期依赖规则修补所有边界问题。模型与规则的组合对当前课程项目是有效的工程方案，但长期提升仍应来自更可靠的数据、系统化的误差分析和真实用户反馈。

8.5 总结

CourseInsight 已实现从中英文课程评价输入到结构化教学反馈输出的完整闭环，包含双语预处理、BERT 情感分类、规则校正、模型回退、课程维度证据、关键词、相似评价、建议生成、批量分析和测试页面。实验说明混合流程在固定案例和独立压力测试中均优于单一模型方案，同时也明确暴露了讽刺识别、隐含语义和语义检索方面的不足。

从课程作业角度，项目具备完整源代码、部署说明、模型指标、消融实验、独立压力测试和可运行界面；从实际应用角度，它提供了一个将大量课程评价快速转化为可追溯改进线索的原型系统。后续通过补充真实场景数据、升级课程维度模型和开展教师用户测试，可以进一步提高其可靠性和应用价值。

9 小组分工与贡献

项目采用模块化协作方式，代码、实验、界面和报告均通过 Git 进行版本管理。两位成员共同参与需求分析和系统方案设计，并根据主要模块分工协作，贡献比例各为 50%。

表 9 小组成员分工与贡献度

成员	学号	主要工作	贡献度
王佳妮	10232140440	参与需求分析与系统方案设计；负责或参与情感分析流程、文本标准化与规则校正、BERT 和传统模型实验、测试用例整理、算法与实验章节撰写及答辩材料准备	50%
柯文丽	10232140444	参与需求分析与系统方案设计；负责或参与 Streamlit 前端、批量分析、课程维度与关键词模块、LLM 建议生成、部署测试说明、界面章节撰写及演示准备	50%
合计	—	全体成员共同完成需求讨论、演示准备与最终检查	100%

协作说明：贡献度综合考虑需求设计、编码实现、数据与实验、文档撰写和答辩准备等工作，经小组成员共同确认。

参考文献

[1] Devlin J, Chang M W, Lee K, Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]. Proceedings of NAACL-HLT, 2019: 4171–4186.

[2] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]. Advances in Neural Information Processing Systems, 2017.

[3] Wolf T, Debut L, Sanh V, et al. Transformers: State-of-the-Art Natural Language Processing[C]. Proceedings of EMNLP: System Demonstrations, 2020: 38–45.

[4] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine Learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825–2830.

- [5] Hugging Face. MungunshagaiT/coursera-reviews Dataset[EB/OL].
[2026-06-14]. <https://huggingface.co/datasets/MungunshagaiT/coursera-reviews>.
- [6] Streamlit Documentation[EB/OL]. [2026-06-14].
<https://docs.streamlit.io/>.
- [7] PyTorch Documentation[EB/OL]. [2026-06-14].
<https://pytorch.org/docs/stable/>.
- [8] jieba 中文分词项目 [EB/OL]. [2026-06-14].
<https://github.com/fxsjy/jieba>.