

华东师范大学

《自然语言处理》

期末报告

CourseInsight: 面向课程评论的中英双语 智能分析系统

小组成员:

姓名: 王佳妮 学号: 10232140440 学院: 计算机科学与技术

姓名: 柯文丽 学号: 10232140444 学院: 计算机科学与技术

2026 年 6 月 25 日

目录

- 1 项目背景 3
 - 1.1 课程评价分析需求 3
 - 1.2 使用场景与目标用户 3
 - 1.3 项目目标与边界 4
- 2 主要功能 4
 - 2.1 系统核心功能 4
 - 2.1.1 单条评价分析 4
 - 2.1.2 批量 CSV 分析 4
 - 2.1.3 固定案例验证 4
 - 2.1.4 模型评估 5
 - 2.2 功能模块划分 5
 - 2.3 功能设计原则 5
- 3 技术方案 6
 - 3.1 技术选型 6
 - 3.2 系统架构 6
 - 3.3 双通道数据流 7
 - 3.4 数据集与标签设计 7
 - 3.5 自动降级与运行稳定性 8
- 4 关键算法与模型原理 8
 - 4.1 双语预处理与情感文本标准化 8
 - 4.2 multilingual BERT 情感分类 9
 - 4.3 长文本滑动窗口推理 10
 - 4.4 规则校正与分层回退 10
 - 4.5 传统情感模型 10
 - 4.6 课程维度与证据识别 11
 - 4.7 关键词提取与证据输出 11
 - 4.8 结构化建议生成 11
 - 4.9 实验结果图表分析 12
- 5 项目特色与创新设计 15
 - 5.1 分层混合情感分析 16
 - 5.2 原文证据保留机制 16
 - 5.3 证据约束的建议生成 16
- 6 界面展示 17
 - 6.1 界面组织方式 17
 - 6.2 首页概览 17

6.3	单条评价分析页面	18
6.4	批量评价分析页面	19
6.5	固定案例验证与模型评估页面	20
7	系统部署与测试	21
7.1	环境要求	21
7.2	安装与启动步骤	22
7.3	源代码组成	22
7.4	模型训练与实验复现	23
7.5	测试策略	23
7.6	代表性测试用例与结果	24
7.7	结果分析	24
8	思考与总结	25
8.1	开发过程中遇到的问题与解决方案	25
8.1.1	多源数据的标签一致性	25
8.1.2	中性与混合评价边界模糊	25
8.1.3	非规范英文表达影响模型输入	25
8.1.4	长文本截断导致信息丢失	25
8.1.5	模型与外部服务可能不可用	25
8.1.6	固定案例不能替代泛化评估	25
8.2	局限性与使用边界	26
8.3	未来改进方向	26
8.4	个人收获与反思	26
8.5	总结	27
9	小组分工与贡献	28
	参考文献	28

1 项目背景

1.1 课程评价分析需求

课程评价是教师了解教学效果的重要来源。学生在评价中通常会同时谈到教师讲解、课程内容、作业量、考试范围、实验环境和学习收获。例如“老师讲得很清楚，但是作业太多”既包含积极反馈，也指出了具体问题。如果只统计评分或简单匹配正负词，系统很容易忽略转折关系和问题发生的位置。

教育文本分析相关研究指出，开放性反馈适合从整体情感、句子情感、实体和方面等层次分析；方面级情感分析在教育场景中的价值，在于帮助教师区分学生对课程内容、授课方式、作业或考核等对象的态度 [1, 2]。基于这一思路，本项目输出积极、中性、消极三类情感标签；同时保留课程维度、关键词和原文证据，便于教师复核系统判断。

面向课程评价这一具体任务，现有处理方式主要有以下困难：

- **评价数量集中。**期末集中收集评价时，教师和课程负责人难以逐条阅读并归纳。
- **表达形式复杂。**评价可能是中文、英文或中英混合文本；也可能包含缩写、拼写错误、否定、建议和讽刺等非规范表达。
- **情感与问题维度不等价。**同一句话整体上可能是中性；但在作业任务或考试安排上包含明确的消极反馈。仅输出情感标签，不足以支持教学改进。
- **结果需要可解释。**教学场景不能只给出“消极”结论；还应说明命中了哪个课程维度、原文依据是什么，以及应优先处理什么问题。

因此，本项目将非结构化课程评价转换为结构化信息。输出内容包括语言、情感倾向、置信度、课程维度、关键词、证据片段和教学改进建议。系统目标不是替代教师判断，而是减少人工整理成本，并为后续复核提供清晰线索。

1.2 使用场景与目标用户

系统主要面向三类使用者：

1. **任课教师：**分析单条典型评价，了解学生认可点和具体困难；辅助调整教学节奏、作业量和实验安排。
2. **课程负责人：**批量导入课程评价 CSV，查看情感分布、课程维度分布和高频关键词；识别需要优先处理的共性问题。
3. **教学管理人员：**通过统一的结构化指标比较不同课程或不同学期的反馈趋势；同时保留可追溯的原文证据。

典型使用流程为：教师上传评价数据；系统进行双语预处理和情感分类；再按照教学内容、授课方式、作业任务、考试安排、实验实践、学习收获六个维度定位问题；最后生成便于教师阅读和复核的总结建议。

1.3 项目目标与边界

本项目构建的是一个可运行、可解释、可降级的 NLP 辅助系统。具体目标如下：

- 支持中文、英文和中英混合课程评价；
- 完成积极、中性、消极三分类，并处理常见混合评价；
- 将评价映射到课程维度，同时展示命中关键词和原文证据；
- 支持首页概览、单条分析、批量分析、固定案例验证和模型评估展示；
- 在 BERT、本地传统模型或外部 API 不可用时保持主要流程可运行；
- 提供可复现的数据处理、模型训练、消融实验和压力测试脚本。

项目在设计阶段区分三类结果。独立测试集用于比较模型性能；固定案例用于验证演示流程；独立压力测试用于观察复杂表达下的鲁棒性。三类结果分别呈现，避免将固定案例上的满分解释为系统整体准确率。

在上述目标基础上，本项目实现了一个面向课程评价的 NLP 应用原型。系统支持单条评价分析、批量 CSV 分析、固定案例验证和模型评估；并将情感倾向、课程维度、关键词、原文证据和教学建议组织为统一输出。具体模型指标、消融实验和压力测试结果将在后文实验部分展开说明。

2 主要功能

2.1 系统核心功能

2.1.1 单条评价分析

用户可以输入中文、英文或中英混合评价，也可以选择系统内置示例。页面返回语言识别结果、情感倾向、置信度、模型来源、课程维度、命中证据和关键词。当启用建议生成时，系统会将结构化分析结果发送给 ChatECNU；接口不可用时，自动使用本地模板生成同样结构的总结与建议。

2.1.2 批量 CSV 分析

系统支持上传包含 `review_text`、`text`、`review`、`comment` 或 `content` 等常见文本字段的 CSV 文件。批量分析输出有效评价数量、积极反馈占比、待关注评论数量、主要关注维度、情感分布、维度排行、高频问题关键词、典型评论证据和逐条分析明细。分析结果可下载为 CSV，适合期末集中评价或问卷开放题的快速整理。

2.1.3 固定案例验证

固定案例验证页面读取 `data/test_cases.csv` 中的 12 条固定案例；一键执行完整 NLP 流程，并同时比较情感标签和课程维度是否符合预期。页面给出固定案例总数、通过案例、失败案例、通过率和逐条结果。该功能用于课堂演示和

回归检查，不作为整体模型效果指标。

2.1.4 模型评估

模型评估页面展示离线实验结果和当前运行状态。页面包括最终实验主模型、测试集 Accuracy、Macro-F1、评估样本数、配置后端、实际运行后端、BERT 权重状态、TF-IDF 模型状态和 LLM 配置状态。同时展示传统分类器对比、BERT 混淆矩阵、分类报告和固定案例消融实验。

2.2 功能模块划分

表 1 系统功能模块与代码对应关系

模块	主要文件	功能说明
前端交互	app.py	提供首页概览、单条分析、批量分析、固定案例验证和模型评估五个页面
文本预处理	preprocess.py、 sentiment_normalizer.py	语言识别、文本清洗、双语分词、缩写展开和受限拼写纠错
情感分析	bert_sentiment.py、 nlp_analyzer.py	BERT 推理、规则校正、TF-IDF 回退和统一结果编排
课程维度	topic_analyzer.py	识别六类课程维度，并返回命中关键词和原文证据
关键词提取	keyword_extractor.py	提取单条评价关键词和批量评价中的高频问题表达
建议生成	llm_client.py	调用 ChatECNU 生成结构化建议，异常时使用本地模板
训练与评估	train_model.py、 train_bert.py、 scripts/	模型训练、指标保存、消融实验、压力测试和报告图表生成

各功能模块在系统中的层次关系见图 1。从评价输入到结构化结果和教学建议的处理顺序见图 2。模块表、总体架构图和数据流图共同说明了页面功能、后端服务与模型资源之间的对应关系。

2.3 功能设计原则

系统功能设计遵循“先结构化分析，再生成自然语言建议”的原则。情感标签由可评估的分类模型与规则模块决定；大语言模型只接收情感、课程维度、关

关键词和证据等结构化结果。这样可以减少生成模型对核心标签的不可控影响，也能够没有 API 时保持分析结果一致。

第二个原则是“输出结论必须尽量附带证据”。课程维度不是只返回一个名称，而是同时记录命中关键词、关键词位置和附近的原文片段。教师可以从“系统判断”快速回到“学生原话”，降低错误归纳带来的风险。

3 技术方案

3.1 技术选型

本项目的技术选型围绕三个要求展开。第一，系统需要能在普通课程项目环境中运行；第二，模型训练、评估和页面展示要能够复现；第三，外部服务或大模型权重不可用时，核心分析流程仍应保留。主要技术栈见表 2。

表 2 主要技术选型与用途

层次	技术或工具	选型理由
开发语言	Python 3.10+	便于整合数据处理、模型训练、前端应用和自动化测试
Web 前端	Streamlit	适合快速构建课程演示型数据应用，支持表格、图表、文件上传和下载
数据处理	Pandas、NumPy	用于 CSV 清洗、批量统计、训练数据划分和结果导出
中文处理	jieba	部署轻量，适合课程领域词汇的基础分词和关键词统计
传统模型	scikit-learn	提供 TF-IDF、Logistic Regression、Naive Bayes、Linear SVM 和评估指标
深度模型	PyTorch、Transformers	支持 multilingual BERT 微调、本地推理、批量推理和模型保存
建议生成	ChatECNU API	将结构化分析结果转换为自然语言教学建议；未配置时使用本地模板
测试工具	unittest	使用 Python 标准库覆盖预处理、模型编排、降级路径和脚本输出

3.2 系统架构

系统采用分层结构，将页面交互、NLP 编排、模型推理、规则知识和外部建议服务分开。前端只调用统一分析接口，不直接依赖某一种模型。更换情感后端或关闭 LLM 时，页面逻辑不需要同步修改。




图 1 CourseInsight 系统分层架构

3.3 双通道数据流




图 2 CourseInsight 双通道数据流

系统对同一条评价保留两种文本表示。原始文本用于页面展示、课程维度、关键词和证据提取；标准化文本只用于情感分类。这样既能提高噪声文本的分类稳定性，也不会因为自动纠错而改变学生原话。

3.4 数据集与标签设计

训练数据共 9120 条。其中 9000 条来自英文 Coursera 课程评论 [3]；120 条为人工中文课程评价。三个情感类别各 3040 条，保持完全均衡。数据以 Coursera 课程评论为主体；人工样本用于覆盖中文、中英混合、作业、考试和实验等课堂演示场景。

表 3 数据来源、用途与结论边界

数据	数量	语言	用途	主要量化结论
Coursera 课程评论	9000	英文	训练、验证和独立测试	是
人工课程评价	120	中文	双语流程验证和课堂演示	否
固定案例	12	中英混合	演示流程验证和回归检查	否
独立压力测试	48	中英混合	复杂表达鲁棒性分析	辅助

Coursera 课程评论主要用于英文情感模型训练和量化评估。人工课程评价样本根据高校课程评价场景构造；不包含真实学生姓名、学号或其他隐私信息。报告中的模型性能结论主要依据固定划分的独立测试集；少量人工样本只用于双语功能验证和测试用例构建。

本项目所说的“中英混合输入支持”，主要指系统输入、预处理、规则识别、课程维度识别和演示流程能够处理中文、英文及中英混合文本。模型量化评估主要基于英文课程评论数据。中文部分目前仍是小规模流程验证，后续需要补充真实中文课程评价数据，才能支撑完整的中文泛化结论。

标签定义为：积极表示主要认可或满意；消极表示主要抱怨或明确问题；中性不仅包含态度不明显的评价，也包含建议型评价和正负信息相对平衡的混合评价。这一定义更符合教学反馈场景。例如“内容很好，但考试范围不清楚”不应被简单压缩为单一的积极或消极结论。

3.5 自动降级与运行稳定性

情感后端默认设置为 AUTO。系统优先加载本地 BERT 权重；若权重缺失、依赖不可用或推理失败，则回退到 TF-IDF Logistic Regression；如果传统模型文件也不可用，则使用规则模型。BERT 推理不强制要求 GPU。当 BERT_DEVICE=auto 时，系统会在 CUDA 可用时使用 GPU，否则使用 CPU。只有强制设置 BERT_DEVICE=cuda 且机器没有 CUDA 时，才会触发设备错误。

建议生成同样具有降级路径。ChatECNU 调用失败或未配置时，本地模板会根据情感、课程维度和证据生成总结、问题与建议。因此，网络异常只影响外部大模型建议；不会影响本地情感分类、课程维度识别和关键词提取。

4 关键算法与模型原理

本项目的核心 NLP 任务包括文本语言识别、情感三分类、课程维度识别、关键词提取和结构化建议生成。其中，情感分类承担主要可量化评估任务；课程维度和证据识别保证结果可解释；LLM 只负责把结构化结果组织成自然语言建议。

4.1 双语预处理与情感文本标准化

基础预处理先删除 URL、异常符号和多余空白，再识别文本语言。中文使用 jieba 分词；英文使用正则表达式分词并过滤常见停用词。为了保留课程领域信息，系统不会删除“作业、考试、实验、讲解、收获”等对教学分析有意义的词。

真实评论中经常出现 tbh、idk、cant、crs 等缩写；也会出现 excelnt、confuzing、uncler 等拼写错误。系统在情感分类前增加独立标准化层，将常见缩写展开；同时只对情感词执行受限纠错。自动纠错必须满足候选唯一、相同词首，且最多只有一次漏字、多字或相邻字母换位。合法词形和技术名词受到保护。部分转换示例如表 4。

表 4 噪声情感文本标准化示例

原始表达	送入情感分类器的标准化表达
Tbh this crs is dificult	To be honest, this course is difficult
I cant recomend this crs	I cannot recommend this course
borng and uncler	boring and unclear
gooooood	good

标准化后的文本只用于情感分类。原始文本继续用于页面展示、关键词、课程维度和证据提取。这种“双文本通道”避免了自动纠错修改学生原话；也保证最终证据能够与用户输入直接对应。

4.2 multilingual BERT 情感分类

BERT 使用 Transformer 编码器；通过双向自注意力建模词语在上下文中的关系 [4, 5]。对于输入 Token 序列 $x_1, x_2, \dots, x_n$ ，模型得到各位置的上下文表示；并使用 [CLS] 位置的最终表示 h_{CLS} 完成三分类：

$$\mathbf{p} = \text{softmax}(W\mathbf{h}_{\text{CLS}} + \mathbf{b}), \quad (1)$$

其中 $\mathbf{p}$ 分别表示消极、中性和积极三个类别的概率。最终标签为概率最大的类别。项目采用 bert-base-multilingual-cased，利用其多语言词表同时处理中文和英文。

表 5 BERT 训练配置

参数	数值	参数	数值
训练/验证/测试集	5472/1368/2280	随机种子	42
训练轮数	2	批大小	8
最大序列长度	160	学习率	2×10^{-5}
权重衰减	0.01	最优模型指标	Macro-F1

验证集用于每轮训练后的模型选择。独立测试集只在训练完成后评估一次。训练时若 CUDA 可用则启用 GPU；若不可用，也可以在 CPU 上运行。部署阶段采用懒加载方式，第一次分析时加载模型，后续请求复用同一实例。

4.3 长文本滑动窗口推理

直接截断长评价会丢失后半部分信息。系统将超过最大长度的 Token 序列按滑动窗口切分。默认最大长度为 160，重叠 32 个 Token，单条评价最多保留 16 个窗口。整条评价的加权分类概率为：

$$\mathbf{p} = \frac{\sum_{i=1}^m w_i \mathbf{p}_i}{\sum_{i=1}^m w_i}. \quad (2)$$

其中， $\mathbf{p}_i$ 表示第 i 个窗口的分类概率； w_i 表示该窗口的有效 Token 数； m 表示窗口数量。使用有效 Token 数加权，可以避免短尾窗口和完整窗口具有相同影响。后端会记录窗口数量、Token 数量和是否达到窗口上限。

4.4 规则校正与分层回退

BERT 能理解大部分上下文；但对课程评价中的混合态度、局部否定和固定业务定义仍可能产生偏差。规则模块统计中英文正负信号，并检测“但是、但、不过、but、however”等转折结构。其主要处理逻辑包括：

- 正负信号同时出现且相对平衡时，将结果校正为中性；
- “不差、并非没有帮助”等否定消极表达作为弱积极信号；
- “不清楚、not useful”等否定积极表达作为消极信号；
- 建议型表达默认保持中性，避免把“希望增加代码示例”误判为强消极；
- 对部分明显讽刺或隐含抱怨使用有限语义规则，但不声称完整解决讽刺识别。

系统默认采用 AUTO 后端，执行顺序为：

$$\text{BERT} + \text{规则校正} \rightarrow \text{TF-IDF Logistic Regression} \rightarrow \text{纯规则模型}. \quad (3)$$

该顺序将语义效果较好的 BERT 放在首位；同时保留体积小、启动快的传统模型，以及无需模型文件的规则兜底。

4.5 传统情感模型

传统模型将预处理后的文本转换为 TF-IDF 向量。词 t 在文档 d 中的权重表示为：

$$\text{tfidf}(t, d) = \text{tf}(t, d) \log \frac{N}{\text{df}(t) + 1}, \quad (4)$$

其中 N 为文档总数， $\text{df}(t)$ 为包含词 t 的文档数。项目使用一元与二元词组、最多 30000 个特征；并比较 Dummy、Logistic Regression、Naive Bayes 和 Linear SVM。最佳传统模型为 Logistic Regression。

表 6 传统模型与 BERT 测试结果

模型	Accuracy	Macro-F1
Dummy Most Frequent	0.3333	0.1667
Naive Bayes	0.6772	0.6785
Linear SVM	0.6811	0.6795
Logistic Regression	0.6904	0.6906
multilingual BERT	0.7461	0.7457

BERT 相比 Logistic Regression 的 Accuracy 提高约 5.57 个百分点。Macro-F1 提高约 5.51 个百分点。BERT 对积极类效果最好；中性类由于混合评价和建议型表达较多，仍是最难识别的类别。

4.6 课程维度与证据识别

系统使用面向课程场景的双语领域词典识别六个维度：教学内容、授课方式、作业任务、考试安排、实验实践和学习收获。例如出现“assignments”和“deadline”时，系统识别为“作业任务”；出现“setup”和“code”时，系统识别为“实验实践”。

对于每个命中维度，系统不仅返回维度名称；还记录最先出现的关键词、出现位置和关键词附近的原文片段。维度结果按首次出现位置排序，因此能够保留评价的叙述顺序。这种方法没有采用复杂主题模型；但在固定课程场景中实现简单、结果稳定，也便于人工检查和扩展词典。

4.7 关键词提取与证据输出

关键词模块统计预处理后词项频次并过滤停用词。在单条分析页面，关键词用于概括当前评价中的核心表达；在批量分析页面，关键词用于定位待关注评论中的高频问题。

关键词、课程维度和原文证据共同进入结构化结果。它们的作用不是替代教师阅读原文，而是帮助教师更快定位“学生在说什么”和“问题属于哪个课程环节”。

4.8 结构化建议生成

大语言模型不直接接收孤立评论并自由判断。系统先生成情感倾向、课程维度、关键词和证据片段；再把这些结构化信息送入建议生成模块。提示词要求输出 summary、problems、suggestions 和 risk level 等固定字段。温度设置为 0.2，以降低输出随机性。

调用失败时，本地模板根据同一结构化输入生成结果。因此，分类和证据不

会受到外部服务状态影响。LLM 生成内容仍需要教师复核；系统提供的是建议文本，而不是自动教学决策。

4.9 实验结果图表分析

本节结合模型对比、混淆矩阵、训练过程、固定案例消融和压力测试结果，说明系统在不同评估设置下的表现。图表数据来自训练输出、模型评估文件和实验日志。训练数据按照 60%、15% 和 25% 划分训练集、验证集和独立测试集；独立测试集规模为 2280 条。

不同情感分类模型的独立测试集结果见图 3。




图 3 独立测试集情感分类模型对比

图 3 将传统基线和最终 BERT 模型置于同一坐标系中。评价指标为 Accuracy 和 Macro-F1。multilingual BERT 的 Accuracy 为 0.7461，Macro-F1 为 0.7457；分别比最佳传统模型 Logistic Regression 提高约 5.57 和 5.51 个百分点。在当前独立测试集划分下，BERT 的上下文表示对课程评价中的转折、否定和混合态度判断有一定帮助。不过，当前主要量化评估仍以英文 Coursera 评论为主；因此不能据此直接推出中文真实课程评价上的完整泛化结论。

BERT 在三类情感上的具体错误分布见图 4。




图 4 multilingual BERT 独立测试集混淆矩阵

图 4 显示，积极类别识别效果最好。中性类别有 228 条被误判为消极、72 条被误判为积极；这是最主要的错误来源。课程评价中的建议型表达、轻度抱怨和正负混合表达仍容易与单一极性混淆。因此，不能只依赖总体指标判断模型效果。

BERT 微调过程见图 5。




图 5 multilingual BERT 微调过程

图 5(a) 显示训练损失在两个 Epoch 内总体下降。图 5(b) 显示验证集 Accuracy 从 0.7003 提升至 0.7230；Macro-F1 从 0.7039 提升至 0.7225。第二轮训练仍带来稳定增益；但验证损失未同步明显下降，因此当前训练轮数保持为 2，以控制过拟合风险和训练成本。

固定案例消融结果见图 6。






图 6 固定案例消融结果

固定案例主要用于课堂演示流程验证，不作为整体模型效果指标。项目分别运行纯规则、TF-IDF、BERT 和完整混合流程。图 6 显示，TF-IDF 单模块通过 7/12；BERT 单模块通过 11/12；完整流程通过 12/12。纯规则同样在这组固定案例上达到满分，原因是案例集中包含较多规则能够直接覆盖的典型表达。因此，项目进一步使用未参与规则开发的独立压力测试检验鲁棒性。

独立压力测试结果见图 7。



(a) 整体 Accuracy 与 Macro-F1



(b) 分类别通过数

图 7 独立压力测试结果

压力测试共 48 条，覆盖缩写、拼写、否定、讽刺、隐含抱怨、中英混合、长文本和混合情感；每类 6 条。压力测试不是随机测试集，而是面向困难表达构造的挑战集。其结果主要反映复杂边界场景下的鲁棒性，不应与 2280 条常规独立测试集指标直接比较。图 7 表明，混合流程在压力测试上的 Accuracy 和 Macro-F1 均高于三个单独模块。其优势主要集中在缩写、拼写错误、否定、中英混合和长文本场景。另一方面，讽刺仅通过 1/6，隐含抱怨仅通过 3/6；这些类型仍是当前系统的主要短板。

5 项目特色与创新设计

本项目的设计重点不在于简单堆叠模型。课程评价的实际难点是混合表达、噪声文本、证据复核和部署环境不稳定。因此，本节将项目特色概括为三点：分层混合情感分析、原文证据保留机制和证据约束的建议生成。长文本滑动窗口和独立压力测试作为这些设计的实现支撑和评估证据，不单独拔高为创新点。

5.1 分层混合情感分析

项目没有将“使用 BERT”本身作为创新点。系统针对课程评价的真实表达方式设计分层混合流程：BERT 负责主要上下文语义判断；规则模块处理课程场景中可明确描述的转折、否定、建议和混合评价；TF-IDF Logistic Regression 与纯规则模型承担自动回退。不同方法承担各自适合的任务，而不是简单投票。

该流程还包含长文本滑动窗口推理。系统没有直接截断超过 160 Token 的评价；而是使用带重叠的窗口，并按每个窗口的有效 Token 数加权聚合概率。后端会记录窗口数量、Token 数和截断标志。这部分设计主要用于减少长评价信息丢失，并为后续界面提示保留数据基础。

固定案例消融结果显示，完整流程在 12 条固定案例上通过 12/12。该结果只说明课堂演示流程能够稳定跑通。由于固定案例中包含较多典型表达，项目没有把它当作整体模型结论；而是另外使用 48 条独立压力测试观察复杂输入下的鲁棒性。

5.2 原文证据保留机制

多数文本清洗流程会直接修改整个输入。如果后续证据片段也基于清洗文本生成，教师看到的证据就可能与学生原话不一致。本项目将“用于分类的标准化文本”和“用于展示与证据的原始文本”分开。缩写展开、重复字母收缩和拼写纠错只进入情感分类通道；课程维度、关键词和证据仍从原文产生。

同时，纠错策略限制在情感词范围内；并要求极小编辑距离与唯一候选。这样可以降低误改课程名、编程库名称或合法英文词形的风险。教师可以从系统输出回到学生原话，判断系统是否正确理解了“作业任务”“考试安排”或“实验实践”等具体维度。

5.3 证据约束的建议生成

系统把大语言模型限制在“表达与归纳”环节，而不是让它直接决定情感和课程问题。提示词要求建议中的问题维度优先来自自己识别的课程维度；证据必须引用原始评论或主题证据。即使 LLM 不可用，本地模板也会输出相同字段。这种结构降低了生成式模型幻觉对核心分析结论的影响。

从课程项目角度看，本项目的主要价值在于将情感分类、规则校正、证据保留、模型回退和建议生成组织成一个较完整的应用流程。独立压力测试包含 48 条样本，每类 6 条；覆盖缩写、拼写错误、否定、讽刺、隐含抱怨、中英混合、长文本和混合情感。完整混合流程通过 34/48 条样本，Accuracy 为 0.7083，Macro-F1 为 0.7217；在这组构造困难样本上高于 rule-only、TF-IDF-only 和 BERT-only 三个单独模块。

同时，压力测试也暴露出系统边界。讽刺类别仅通过 1/6，隐含抱怨仅通过 3/6，说明有限规则和当前训练数据还不足以稳定处理复杂语用现象。因此，本项目不将压力测试结果解释为真实场景准确率，而是将其作为发现失败类型和

确定后续改进方向的依据。

6 界面展示

6.1 界面组织方式

CourseInsight 使用 Streamlit 构建宽屏数据应用。页面按照“输入、分析、结果复核”的顺序组织。侧边栏提供首页概览、单条分析、批量分析、固定案例验证和模型评估五个入口；同时显示当前情感模型后端和 LLM 服务状态。页面主体采用指标卡、图表、表格和证据卡片组合；重点展示情感倾向、关键词、命中维度和教学建议。

界面设计遵循以下原则：

- **任务导向：**五个页面分别对应概览、单条输入、批量处理、演示验证和模型评估；
- **状态可见：**页面显示 BERT、TF-IDF 或规则模式，以及 LLM 是否使用本地兜底；
- **证据优先：**单条分析先展示情感倾向和置信度，再展示关键词、维度证据和教学建议；
- **便于复核：**批量页保留典型认可评论、典型问题评论和逐条分析明细；
- **支持演示：**固定案例页用于课堂演示流程验证，模型评估页展示离线指标和运行状态。

6.2 首页概览

首页概览展示系统定位、当前模型状态、数据规模、支持输入方式和输出结果类型。当前页面将输出概括为四类：情感倾向、关键词、命中维度和教学建议。从评论文本到教学建议的流程见图 8。




图 8 首页概览中的系统状态、数据规模和处理流程

6.3 单条评价分析页面

单条分析页面提供中文、英文和中英混合三类示例。用户输入评价后，页面展示情感倾向、置信度、关键词数量和建议状态；随后给出命中维度、关键词标签、原文证据和教学改进建议。图 9 展示了一条中文积极评价的分析结果。

单条分析

输入一条课程评价，查看模型给出的情感判断、关键词、维度证据和改进建议。

输入课程评价

可直接输入，也可以选择下方示例评价。

中文评价

英文评价

中英混合

评价文本

老师讲课很清楚，课程内容和知识点组织得很好，案例也帮助我理解重点，整体收获很多。

生成改进建议 ?

开始分析

分析结果总览

情感倾向

积极

根据评价文本判断整体反馈倾向。

置信度

96.0%

模型对当前判断的置信程度。

关键词

6个

内容、讲课、清楚、知识

建议状态

已生成

已结合评价内容生成教学建议。

命中维度与证据

教学内容

内容

知识点

案例

重点

命中依据

"老师讲课很清楚，课程内容和知识点组织得很好，案例也帮助我理解重点，整体收获很多。"

学习收获

帮助

理解

收获

命中依据

"老师讲课很清楚，课程内容和知识点组织得很好，案例也帮助我理解重点，整体收获很多。"

授课方式

讲课

清楚

命中依据

"老师讲课很清楚，课程内容和知识点组织得很好，案例也帮助我理解重点，整体收获很多。"

输入一条课程评价，查看模型给出的情感判断、关键词、维度证据和改进建议。

输入课程评价

可直接输入，也可以选择下方示例评价。

中文评价

英文评价

中英混合

评价文本

老师讲课很清楚，课程内容和知识点组织得很好，案例也帮助我理解重点，整体收获很多。

☒ 生成改进建议

开始分析

分析结果总览

情感倾向

积极

根据评价文本判断整体反馈倾向。

置信度

96.0%

模型对当前判断的置信程度。

关键词

6 ↑

内容、讲课、清楚、知识

建议状态

已生成

已结合评价内容生成教学建议。

命中维度与证据

教学内容

内容 知识点 案例 重点

命中依据

“老师讲课很清楚，课程内容和知识点组织得很好，案例也帮助我理解重点，整体收获很多。”

学习收获

帮助 理解 收获

命中依据

“老师讲课很清楚，课程内容和知识点组织得很好，案例也帮助我理解重点，整体收获很多。”

授课方式

讲课 清楚

命中依据

“老师讲课很清楚，课程内容和知识点组织得很好，案例也帮助我理解重点，整体收获很多。”

图 9 单条评价分析页面的输入、情感倾向、维度证据和建议摘要

6.4 批量评价分析页面


批量分析页面支持上传 CSV 或加载内置样本。页面先展示评论总数、积极反馈占比、待关注评论数量和主要关注维度；再展示情感分布、维度关注排行、高频问题关键词、高频问题维度和典型评论证据。分析明细可下载为 CSV，便于后续人工复核和归档。批量页的核心统计区域见图 10。




图 10 批量评价分析页面的概览指标、分布图和问题定位

6.5 固定案例验证与模型评估页面

固定案例验证页面用于一键运行 12 条固定案例。页面显示测试用例预览、验证说明、通过案例、失败案例、通过率和逐条验证明细。模型评估页面展示最终实验主模型、测试集 Accuracy、Macro-F1、评估样本数、当前运行后端、BERT 权重状态、TF-IDF 模型状态、LLM 配置状态、模型对比表、混淆矩阵和分类报告。两个页面的主要结果区域见图 11。



(a) 固定案例验证结果



(b) 模型评估与运行状态

图 11 固定案例验证与模型评估页面

7 系统部署与测试

7.1 环境要求

表 7 推荐运行环境

项目	要求或说明
操作系统	Windows 10/11，本报告命令以 Windows PowerShell 为例
Python	3.10 或以上版本
基础依赖	Streamlit、Pandas、NumPy、jieba、scikit-learn、Matplotlib 等
BERT 依赖	PyTorch、Transformers、Accelerate
硬件	基础功能可使用 CPU；BERT 可在 CPU 上运行，CUDA GPU 主要用于加速
模型文件	传统模型约 1.3 MB；BERT 权重约 711 MB，需要单独携带或下载
可选服务	ChatECNU API；未配置时自动使用本地建议模板

Git 仓库保留 BERT 配置、Tokenizer、训练参数和评估指标，但不提交 `model.safetensors`。若权重不存在，系统会自动降级到 TF-IDF 或规则后端。

页面侧边栏会显示当前实际运行的情感后端，避免把降级结果误认为 BERT 推理结果。

7.2 安装与启动步骤

1. 在项目根目录创建并激活虚拟环境：

```
python -m venv .venv
.venv\Scripts\activate
```

2. 安装基础依赖和 BERT 依赖：

```
pip install -r requirements.txt
pip install -r requirements-bert.txt
```

3. 如需使用大语言模型建议，将 `.env.example` 复制为 `.env`，填写 `LLM_API_KEY`、`LLM_BASE_URL` 和 `LLM_MODEL`。不配置 API 也不会影响情感分析、课程维度和本地建议生成。
4. 确认 BERT 模型目录为 `outputs/bert_model_final`，或通过 `BERT_MODEL_PATH` 指定其他目录。若没有 BERT 权重，系统自动使用传统模型。
5. 启动应用：

```
streamlit run app.py
```

6. 浏览器访问 Streamlit 输出的本地地址，依次检查首页概览、单条分析、批量分析、固定案例验证和模型评估页面。

7.3 源代码组成

主要内容如下：

- `app.py`: Streamlit 应用入口及五个功能页面；
- `src/`: 预处理、BERT 与传统模型推理、课程维度、关键词和建议生成模块；
- `scripts/`: 数据构建、消融实验、压力测试和报告图表生成脚本；
- `tests/` 与 `data/test_cases.csv`: 自动测试和固定演示案例；
- `requirements.txt`、`requirements-bert.txt` 和 `.env.example`: 依赖与配置模板；
- `models/`: 可直接运行的传统模型文件。BERT 权重体积较大，随最终电子材料单独提交；缺少该权重时系统会自动回退到传统模型，基本功能仍可运行。

7.4 模型训练与实验复现

传统模型训练命令如下：

```
python -m src.train_model ^  
--data data/processed/bilingual_reviews_train.csv ^  
--model-dir models
```

BERT 训练命令如下：

```
python -m src.train_bert ^  
--data data/processed/bilingual_reviews_train.csv ^  
--model-name bert-base-multilingual-cased ^  
--output-dir outputs/bert_model_final ^  
--metrics-path outputs/bert_metrics_final.json
```

固定案例消融实验和独立压力测试分别使用：

```
python scripts/run_ablation_experiment.py ^  
--cases data/test_cases.csv ^  
--output-dir outputs/reports/final_model ^  
--model-dir models  
  
python scripts/run_stress_test.py ^  
--cases data/stress_test_cases.csv ^  
--output-dir outputs/reports/stress_test_final ^  
--model-dir models
```

7.5 测试策略

项目测试分为三个层次：

1. **单元与集成测试：**覆盖文本清洗、语言识别、分词、情感标准化、长文本窗口、课程维度证据、模型优先级、降级路径、LLM 本地兜底、数据脚本和页面数据格式。
2. **固定案例：**12 条中英文课程评价，用于验证课堂演示中的情感和课程维度结果。
3. **独立压力测试：**48 条复杂表达，用于观察缩写、拼写、否定、讽刺、中英混合和长文本下的系统表现。

单元测试运行命令为：

```
python -m unittest discover -s tests
```


7.6 代表性测试用例与结果

表 8 给出 8 个代表性案例，结果来自当前完整混合流程的固定案例实验。

表 8 代表性测试用例与结果

编号	输入评价	预期情感	预期课程维度	结果
1	老师讲课很清楚，内容也很有用	积极	授课方式、教学内容	通过
2	作业太多了，每周都做不完	消极	作业任务	通过
3	实验环境配置太复杂，经常报错	消极	实验实践	通过
4	课程内容不错，但是考试范围不太明确	中性	教学内容、考试安排	通过
5	这门课难度比较大，但学完之后收获很多	中性	教学内容、学习收获	通过
6	希望老师能多给一些代码示例	中性	实验实践、教学内容	通过
7	The instructor explains concepts clearly and the examples are helpful	积极	授课方式、学习收获	通过
8	The assignments are too many and the deadlines are stressful	消极	作业任务	通过

7.7 结果分析

固定案例中，TF-IDF 单独通过 7/12；BERT 单独通过 11/12；完整流程通过 12/12。该结果说明课堂演示流程能够稳定跑通。但由于固定案例包含较多典型规则表达，不能把 12/12 解释为整体准确率。BERT 改善了英文上下文和中文短句的判断；规则校正进一步处理了“内容不错，但是考试范围不明确”等混合评价。

48 条独立压力测试中，完整流程通过 34 条。Accuracy 为 0.7083，Macro-F1 为 0.7217。中英混合类别通过 6/6；缩写、拼写、否定和长文本类别均通过 5/6。这说明针对噪声文本和长文本的设计有效。讽刺类别仅通过 1/6，是当前最主要的失败来源；因此报告不以固定案例满分替代独立测试结论。

8 思考与总结

8.1 开发过程中遇到的问题与解决方案

8.1.1 多源数据的标签一致性

课程评价来自公开评论与人工构造场景。不同来源的表达风格和信息密度存在差异。项目首先统一积极、中性、消极的标注标准；再对三类标签进行均衡采样，并固定训练、验证、测试划分。这样可以让传统模型、BERT 和混合流程在相同数据基础上比较；也避免数据来源差异直接干扰实验结论。

8.1.2 中性与混合评价边界模糊

三分类任务中，中性类别不仅包括没有明显态度的文本；也包括建议型表达和正负混合评价。传统 TF-IDF 模型容易只关注强情感词；BERT 也可能将转折句推向某一极性。项目通过统一标签定义、转折规则和正负信号平衡判断，将“讲解清楚但作业太多”归入中性，并保留各课程维度的具体问题。

8.1.3 非规范英文表达影响模型输入

在线评论中存在缩写、漏字、重复字母和拼写错误。若全面启用通用拼写纠错，容易误改课程名和技术词；若完全不处理，又会损失情感信号。最终方案是在情感通道中使用受限词典和极小编辑操作，只纠正高置信度情感词。原文仍用于证据展示，避免证据与学生原话不一致。

8.1.4 长文本截断导致信息丢失

BERT 的输入长度有限，直接截断可能只保留评价开头。项目实现带重叠的滑动窗口，并按有效 Token 数加权聚合各窗口概率。同时限制最大窗口数并记录截断元数据。这样可以在计算量可控的前提下，尽量保留长评价中的后续信息。

8.1.5 模型与外部服务可能不可用

BERT 权重体积较大，加载需要时间。课堂演示时，ChatECNU API 也可能因为网络或配置问题不可用。项目将模型加载设计为懒加载和实例复用；情感分析提供 BERT、TF-IDF、规则三级后端；建议生成提供 API 与本地模板两级方案。前端显示实际运行状态，避免用户误以为系统始终在使用同一种模型。

8.1.6 固定案例不能替代泛化评估

固定案例适合演示，但规则可能因为覆盖这些表达而取得较高成绩。项目额外建立 48 条独立压力测试，并按表达类型和语言统计结果。压力测试暴露了讽刺和隐含抱怨的不足；也避免将 12/12 的演示结果解释为整体准确率 100%。

8.2 局限性与使用边界

1. **中文真实数据不足。**当前主要量化评估基于英文 Coursera 评论；120 条中文样本只用于流程验证和课堂演示，不能支撑完整中文泛化结论。
2. **真实场景覆盖仍可扩展。**当前数据尚未覆盖更多学科、学期和院校环境；跨场景效果仍需继续验证。
3. **课程维度依赖词典。**领域词典易解释、部署轻量；但难以识别没有显式关键词的隐含主题，也需要人工维护新课程术语。
4. **讽刺和隐含抱怨识别较弱。**压力测试中讽刺通过率仅 1/6；说明有限规则和当前训练数据不足以处理复杂语用现象。
5. **大模型建议需要人工复核。**系统要求 LLM 引用证据；但生成内容仍不能直接作为教学决策，教师需要结合课程实际情况判断。
6. **BERT 模型文件较大。**BERT 权重约 711 MB；在 CPU 上可以运行，但首次加载和推理速度不如传统模型。
7. **尚未进行真实用户研究。**当前主要验证算法和系统流程；还缺少教师实际使用后的可用性评价与改进效果追踪。

8.3 未来改进方向

后续改进可以从三个方向展开：补充真实中文课程评价数据，改进课程维度标注与识别方法，并对复杂表达开展更系统的测试。具体工作包括：

- 与真实课程合作，在脱敏和授权前提下收集跨课程、跨学期评价，并由多人复核标签；
- 对不同语言 and 不同课程场景进行分层评估，增加置信区间和跨学期测试；
- 将课程维度识别升级为多标签分类，同时继续保留证据抽取和规则解释；
- 针对讽刺、隐含抱怨和复杂否定构建专门训练集，而不是无限增加手写规则；
- 引入模型蒸馏、量化或 ONNX Runtime，减小部署体积并提升 CPU 推理速度；
- 加入课程、学期和教师维度的历史趋势对比，以及人工反馈修正机制；
- 对 LLM 建议增加事实一致性检查、敏感信息脱敏和人工确认 workflow。

8.4 个人收获与反思

通过这次项目，我们对自然语言处理系统的完整开发流程有了更具体的认识。最开始我们更多关注模型能否完成情感分类，但随着项目推进，才发现一个可用的系统还需要考虑数据来源、标签定义、输入清洗、模型回退、界面展示和结果解释等多个环节。尤其是在课程评价这样的实际场景中，系统不能只给出一个情感标签，还需要告诉用户判断依据是什么、问题集中在哪些课程环节，以及这些结果是否值得进一步人工复核。

在模型实现过程中，我们对传统机器学习方法和 BERT 模型的差异有了更直观的理解。TF-IDF Logistic Regression 训练和部署都比较轻量，适合作为稳定的基础模型；multilingual BERT 在处理上下文、转折和否定表达时效果更好，但也带来了模型文件较大、加载较慢和环境依赖更多的问题。因此，项目最后没有简单地只保留一个模型，而是设计了 BERT、传统模型和规则方法的分层回退流程。这个过程让我们意识到，课程项目中的“效果好”不仅指指标更高，也包括在不同运行环境下能否稳定工作。

项目中比较有启发的一点是标签和评价场景之间的关系。课程评论里经常出现“老师讲得很清楚，但是作业太多”这类混合表达，如果只按积极或消极二分，很容易丢失学生真正想表达的问题。因此，我们在情感分类之外加入了课程维度、关键词和原文证据，希望把评论中的具体关注点保留下来。这样做虽然不能完全解决语义理解问题，但能让教师更快看到学生反馈集中在哪些方面，也便于判断系统分析是否合理。

在实验评估方面，我们也更加注意不同结果的使用边界。固定案例适合课堂展示和流程检查，但不能代表模型的泛化能力；独立测试集更适合用于模型对比；压力测试则能暴露系统在复杂表达下的不足。比如当前系统对缩写、拼写错误、中英混合和长文本有一定改进，但面对讽刺、隐含抱怨等表达时仍然不稳定。这些结果提醒我们，报告中不能只展示好看的指标，也需要说明失败情况和适用范围。

这次项目也暴露了一些不足。由于时间和数据限制，中文真实课程评价样本仍然偏少，中文和中英混合输入更多依靠规则和小规模测试验证；课程维度识别主要基于词典，对隐含主题的识别能力有限；LLM 生成的教学建议虽然能提高可读性，但仍然需要教师根据真实教学情境判断。后续如果继续完善，可以重点补充真实中文评价数据，改进维度标注方式，并对复杂表达进行更系统的测试。

总体来说，这次项目让我们不只是练习了文本预处理、TF-IDF、BERT 和模型评估等课程内容，也尝试把这些方法整合成一个面向具体任务的应用系统。相比单独完成一个分类模型，我们对 NLP 项目的工程实现、结果解释和使用边界都有了更实际的理解。

8.5 总结

CourseInsight 已实现从中文、英文及中英混合课程评价输入到结构化教学反馈输出的基本闭环。系统包含双语预处理、BERT 情感分类、规则校正、模型回退、课程维度证据、关键词、建议生成、批量分析、固定案例验证和模型评估页面。BERT 在独立测试集上优于传统情感分类模型；完整混合流程在固定案例中能够稳定跑通演示流程，并在独立压力测试中表现出比单独模块更好的整体鲁棒性。同时，讽刺识别、隐含抱怨和中文真实数据不足仍是当前系统的主要问题。

从课程项目完成度看，本项目不仅实现了可运行界面，也保留了源代码、部署步骤、模型评估结果和测试脚本，能够支持课堂演示和基本复现。作为应用原型，它可以把大量课程评价快速整理为可复核的改进线索。后续通过补充真实场

景数据、升级课程维度识别方法和开展教师用户测试，可以进一步提高系统可靠性。

9 小组分工与贡献

项目采用模块化协作方式，代码、实验、界面和报告均通过 Git 进行版本管理。

表 9 小组成员分工与贡献度

成员	学号	主要工作	贡献度
王佳妮	10232140440	参与需求分析与系统方案设计；主要负责项目框架、数据集构建、情感分析流程编排、BERT 训练及评估、消融实验、压力测试和报告整理	50%
柯文丽	10232140444	参与需求分析与系统方案设计；主要负责数据集构建、课程维度识别、Streamlit 前端迭代、大模型建议生成模块和报告整理	50%
合计	—	全体成员共同完成需求讨论、演示准备与最终检查	100%

协作说明：贡献度综合考虑需求设计、编码实现、数据与实验、报告和 PPT、答辩准备等工作，经小组成员共同确认为各 50%。

参考文献

[1] SHAIK T, TAO X, DANN C, et al. Sentiment analysis and opinion mining on educational data: a survey[EB/OL]. 2023[2026-06-14]. <https://arxiv.org/abs/2302.04359>.

[2] HAJRIZI R, PIREVA NUÇI K. Aspect-based sentiment analysis in education domain[EB/OL]. 2020[2026-06-14]. <https://arxiv.org/abs/2010.01429>.

[3] Hugging Face. MungunshagaiT/coursera-reviews dataset[EB/OL]. [2026-06-14]. <https://huggingface.co/datasets/MungunshagaiT/coursera-reviews>.

[4] DEVLIN J, CHANG M W, LEE K, et al. BERT: pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of NAACL-HLT. 2019: 4171-4186.

- [5] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]// Advances in Neural Information Processing Systems. 2017.